

Table des matières

Chapitre 1	État de l’Art & Contexte Général	2
1.1	Introduction	2
1.2	Entreprise d’Accueil	2
1.2.1	ACTIA Engineering Services	3
1.2.2	Laboratoire Synergy	4
1.3	Contexte du Projet — Industrie 4.0 et IA Embarquée	5
1.4	Problématique et Solution Proposée	7
1.5	Objectifs du Projet	8
1.6	Méthodologie de Travail	9
1.6.1	CRISP-DM appliqué à Sonic AI	9
1.6.2	Sprints agiles pour l’embarqué	10
1.6.3	Planification du Projet	11
1.7	Maintenance Industrielle et Industrie 4.0	11
1.7.1	Évolution des Paradigmes de Maintenance	11
1.7.2	IIoT, Edge AI et TinyML comme Enablers	12
1.7.3	Surveillance Acoustique — Avantages et Défis	13
1.8	Détection d’Anomalie Acoustique — État de l’Art	14
1.8.1	Formalisation du Problème	14
1.8.2	Approches Non Supervisées	14
1.8.3	Approches Supervisées	15
1.8.4	Analyse des Lacunes et Contributions de Sonic AI	15
1.9	Traitement du Signal Acoustique — Fondements Théoriques	17
1.9.1	Représentations Temps-Fréquence	17
1.9.2	Wavelet Packet Transform (WPT)	18
1.9.3	Famille d’Ondelettes Coiflet-5	19
1.9.4	Descripteurs Statistiques par Nœud WPT	20
1.9.5	Sélection de Features par Divergence Jensen-Shannon	21
1.9.6	Filtrage IIR Butterworth	21
1.10	Conclusion	23

1.1 Introduction

Avant de plonger dans les détails techniques du système que nous avons construit, il nous semble utile — et honnête — de poser clairement le cadre dans lequel ce projet est né. **Sonic AI** n'est pas sorti de nulle part : il répond à un besoin industriel précis, identifié au sein d'ACTIA Engineering Services, et sa conception a été guidée à chaque étape par des contraintes réelles plutôt que par des hypothèses idéales de laboratoire. Ce chapitre retrace ce chemin, depuis l'entreprise qui nous a accueillis jusqu'aux fondements théoriques qui sous-tendent nos choix d'ingénierie.

Concrètement, nous abordons sept grandes thématiques dans l'ordre suivant. La Section 1.2 présente ACTIA Engineering Services et le cadre institutionnel du projet. La Section 1.3 explique pourquoi l'Industrie 4.0 rend ce genre de travail non seulement possible mais nécessaire. La Section 1.4 formule la problématique et les objectifs avec les chiffres qui nous ont servi de boussole tout au long du projet. La Section 1.5 décrit comment nous avons organisé notre travail en combinant CRISP-DM et des sprints agiles. La Section 1.6 remonte aux origines de la maintenance prédictive pour comprendre où nous nous situons aujourd'hui. La Section 1.7 passe en revue ce que d'autres ont déjà fait dans ce domaine, ce qui fonctionne, ce qui ne fonctionne pas, et ce qui manque encore. La Section 1.8, enfin, pose les bases mathématiques et théoriques du traitement du signal dont nous aurons besoin pour comprendre le pipeline présenté au Chapitre 2.

1.2 Entreprise d'Accueil

Ce projet de fin d'études a été conduit au sein du **Laboratoire Synergy**, un espace de recherche et développement co-crée par **ACTIA Engineering Services** et **SUP'COM**. Ce qui rend ce cadre particulier, c'est justement cette double nature : ni purement académique, ni purement industriel, mais résolument les deux à la fois. Cette section présente les organisations qui ont rendu ce travail possible et

explique pourquoi leur association constitue un terreau fertile pour ce type de projet ambitieux.

1.2.1 ACTIA Engineering Services

1.2.1.1 Présentation Générale

ACTIA Engineering Services (ACTIA ES) ACTIA Engineering Services [2024] a ouvert ses portes à Tunis en 2005 avec une poignée de cinq ingénieurs fondateurs. Vingt ans plus tard, cette filiale tunisienne du groupe ACTIA s'est transformée en un centre de R&D reconnu à l'échelle nationale, capable de prendre en charge des projets qui touchent aussi bien aux systèmes embarqués de bas niveau qu'à l'intelligence artificielle appliquée. Cette trajectoire n'est pas le fruit du hasard : elle reflète une culture d'entreprise où l'excellence technique n'est pas un slogan mais une exigence quotidienne. Les domaines dans lesquels ACTIA ES est active témoignent de cette diversité assumée :

- Développement de systèmes embarqués et de firmware (bare-metal, RTOS, ARM Cortex-M/A)
- Ingénierie d'applications web et mobiles orientées supervision industrielle et tableaux de bord IIoT
- Conception et prototypage de systèmes mécatroniques et électroniques
- Tests fonctionnels, validation et qualification de produits selon les normes sectorielles
- Support à la certification réglementaire et conception d'outillages de production sur mesure



FIGURE 1 – Logo d'ACTIA Engineering Services ACTIA Engineering Services [2024]

1.2.1.2 Groupe ACTIA

Pour comprendre ACTIA ES, il faut d'abord comprendre le groupe qui l'a créée. Le groupe ACTIA ACTIA Engineering Services [2024], né en 1986 à Toulouse d'une équipe d'ingénieurs passionnés d'électronique embarquée, a grandi pour devenir un acteur mondial dans les systèmes électroniques pour la mobilité connectée et durable. Ce qui le distingue de beaucoup de ses concurrents, c'est une double posture rare : être à la fois fournisseur de produits pour les grands équipementiers automobiles et prestataire de services d'ingénierie pour des clients aux exigences très élevées

dans les secteurs du transport terrestre, aérien et maritime. Cette maîtrise *end-to-end* — de la conception initiale à la validation réglementaire finale — explique naturellement l'intérêt croissant du groupe pour les thématiques de l'intelligence artificielle embarquée et du TinyML Warden and Situnayake [2019], qui constituent aujourd'hui l'une de ses directions stratégiques.

1.2.1.3 Engagement Qualité

Il serait facile d'aligner des certifications sans que celles-ci ne traduisent quoi que ce soit de réel. Ce n'est pas le cas ici. L'engagement d'ACTIA ES pour la qualité ACTIA Engineering Services [2024] se lit dans ses certifications, certes, mais aussi dans la façon dont les équipes travaillent au quotidien : rigueur de la documentation, traçabilité des décisions techniques, culture du test et de la validation à chaque étape. Les distinctions obtenues au fil des années en sont la confirmation externe :

- **Certifications** : ISO 9001 :2015, ISO 17025 :2017, ISO 27001 :2022, CMMI Dev v1.3
- **Récompenses** :
 - **2021** : 1^{er} prix au Concours National Tunisien d'Innovation
 - **2020** : Prix RH pour l'excellence dans la gestion des ressources humaines durant la pandémie Covid-19
 - **2019** : Reconnaissance pour l'investissement en innovation
 - **2017** : 1^{er} Prix National Qualité



FIGURE 2 – Certifications de ACTIA ES ACTIA Engineering Services [2024]

1.2.2 Laboratoire Synergy

Le Laboratoire Synergy ACTIA Engineering Services [2024] est sans doute l'élément le plus singulier du contexte de ce projet. Inauguré le 7 mars 2023 au sein de SUP'COM, cet espace de 130 m² incarne un pari simple mais difficile à tenir : faire travailler ensemble, sur des problèmes réels, des chercheurs académiques et des ingénieurs industriels. Le laboratoire est centré sur les véhicules connectés, la conduite autonome et la mobilité intelligente — des domaines où l'intelligence artificielle embarquée joue un rôle central, ce qui en fait un environnement naturellement adapté à un projet comme Sonic AI.

Sur le plan institutionnel, le laboratoire a bénéficié du cofinancement de DEG Impulse via le programme développement du Ministère fédéral allemand de la Coopération économique et du Développement (BMZ). Ce soutien international ne se limite pas à une question de budget : il confère au laboratoire une légitimité et une visibilité qui ont contribué à attirer des projets ambitieux. C'est dans cet écosystème, entre les équipements de recherche de SUP'COM et les exigences industrielles d'ACTIA ES, que Sonic AI a pris forme.



FIGURE 3 – Logo du Laboratoire Synergy

1.3 Contexte du Projet — Industrie 4.0 et IA Embarquée

Quand on parle d'**Industrie 4.0** Lasi et al. [2014], on parle en réalité d'un changement profond dans la manière dont les usines pensent et se comportent. Depuis que ce concept a été formalisé en Allemagne en 2011, la convergence des systèmes cyber-physiques (CPS), de l'Internet des Objets Industriel (IIoT), du *cloud computing* et de l'intelligence artificielle a transformé des milliers d'usines dans le monde. Aujourd'hui, une machine industrielle bien équipée ne se contente plus d'exécuter des tâches : elle surveille son propre état, génère des données en continu, et peut — si le système est bien conçu — donner l'alerte avant de tomber en panne.

Trois briques technologiques sont particulièrement importantes pour comprendre pourquoi un projet comme Sonic AI devient possible aujourd'hui. L'IIoT permet de couvrir une usine entière de capteurs peu coûteux qui collectent en permanence des informations sur l'état des machines. L'*Edge Computing* déplace une partie du traitement de ces données directement sur le terrain, réduisant la latence à quelques millisecondes et s'affranchissant des contraintes de réseau. Le **TinyML** Warden and Situnayake [2019], enfin, est la pièce manquante qui rend le tout autonome : grâce à lui, un modèle d'apprentissage automatique peut s'exécuter sur un microcontrôleur consommant quelques milliwatts, dans un boîtier plus petit qu'une pièce de monnaie.

Dans ce contexte, la maintenance des équipements industriels prend une dimension nouvelle. McKinsey McKinsey & Company [2023] l'exprime en chiffres qui donnent le vertige : 260 000 dollars perdus par heure d'arrêt non planifié dans l'industrie lourde, et jusqu'à 15 % des coûts d'exploitation annuels engloutis par des pannes d'équipements. Pour ACTIA ES, dont les clients opèrent dans des environnements où la disponibilité des machines est critique, la capacité à proposer une solution de diagnostic embarqué — qui fonctionne sans serveur, sans connexion réseau, sans aucune dépendance externe — représente exactement le type de valeur ajoutée qu'ils cherchent.




FIGURE 4 – Technologies convergentes de l'Industrie 4.0

1.4 Problématique et Solution Proposée

Au cœur de ce projet se trouve une tension que tout ingénieur embarqué connaît bien : on veut un système intelligent, précis, explicable — et on doit le faire tenir dans un microcontrôleur qui n'a ni la mémoire ni la puissance d'un ordinateur de bureau. Pour Sonic AI, la contrainte était claire dès le départ : détecter des anomalies acoustiques industrielles avec un F1-score supérieur à 0.90, même quand le bruit ambiant est plus fort que le signal de la machine ($\text{SNR} = -6 \text{ dB}$), tout en s'exécutant en moins de 10 ms sur un STM32F429 équipé d'un ARM Cortex-M4 à 168 MHz, 256 KB de RAM et 2 MB de Flash.

Formulée de manière plus précise, la question centrale du projet est la suivante : *comment concevoir et déployer un système embarqué de détection d'anomalies acoustiques industrielles capable d'opérer en temps réel sur un STM32F429 (ARM Cortex-M4, 168 MHz), en maintenant un F1-score ≥ 0.90 sur le dataset MIMII à $\text{SNR} = -6 \text{ dB}$, une latence d'inférence $\leq 10 \text{ ms}$, et en intégrant un mécanisme d'explicabilité des décisions par SHAP Lundberg and Lee [2017] ?*

Pour répondre à cette question, nous avons construit un pipeline supervisé original qui articule cinq blocs complémentaires :

- Une décomposition acoustique par **Wavelet Packet Transform de niveau 4** (WPT-L4, famille Coiflet-5), qui découpe le spectre en 16 sous-bandes uniformes de 500 Hz couvrant $[0, 8\,000] \text{ Hz}$
- Une sélection de features par **divergence Jensen-Shannon** (JSD) appliquée séparément pour chaque machine, qui réduit la dimensionnalité de 66 à 33–55 features en gardant uniquement ce qui discrimine vraiment
- Un classifieur **XGBoost** optimisé par Particle Swarm Optimization (PSO), converti en ONNX et déployé via STM32Cube.AI avec 396 KB de Flash, 468 B de RAM d'activations et une latence mesurée *on-target* de 3,37 ms
- Un moteur de décision hybride à 5 couches (EMA, dérivée, CUSUM, hystérésis, multi-fenêtres) conçu pour éviter les fausses alarmes sans sacrifier la sensibilité
- Une couche d'explicabilité TreeSHAP Lundberg and Lee [2017] accessible via une interface Flask, qui permet à l'opérateur de comprendre pourquoi une anomalie a été détectée




FIGURE 5 — Architecture système complète de Sonic AI — des 4 couches logicielles aux performances mesurées *on-target*

1.5 Objectifs du Projet

Un projet d'ingénierie sans objectifs mesurables n'est qu'un projet d'exploration. Dès le début de ce travail, nous avons voulu nous donner des critères d'acceptance précis, testables sur la vraie cible matérielle — pas sur une simulation, pas sur un serveur de calcul — afin de pouvoir dire à la fin, sans ambiguïté, si le système fait ce qu'on lui demande. Ces objectifs sont les suivants :

- **O1 — Précision de classification :** atteindre un F1-score ≥ 0.90 sur les quatre machines du dataset MIMII (pompe, ventilateur, glissière, vanne) en conditions difficiles, SNR = -6 dB Purohit et al. [2019]
- **O2 — Latence d'inférence embarquée :** réaliser la chaîne complète DSP + inférence ML + décision en ≤ 10 ms *on-target*, mesurée sur le STM32F429 @ 168 MHz
- **O3 — Empreinte Flash :** maintenir le modèle ONNX quantifié dans une empreinte Flash ≤ 500 KB après conversion via STM32Cube.AI
- **O4 — Empreinte RAM :** ne pas dépasser 1 KB de RAM d'activations lors de l'inférence, mesuré *on-target*
- **O5 — Réduction dimensionnelle :** passer de 66 features brutes à 33–55 features sélectionnées sans perdre plus de 0,5 % de performance discriminante
- **O6 — Modèle unifié multi-machine :** couvrir les 4 types de machines avec un seul graphe ONNX piloté par un sélecteur *one-hot*, sans dupliquer le binaire embarqué

L’ambition finale est de livrer à ACTIA ES une brique algorithmique mature, documentée et directement intégrable dans ses futurs produits de maintenance prédictive embarquée.

1.6 Méthodologie de Travail

Mener de front une phase de recherche en machine learning et une phase de développement firmware embarqué est délicat. Les deux mondes ont des rythmes différents, des critères de succès différents, et des risques différents. Pour ne pas sacrifier l’un à l’autre, nous avons adopté une approche hybride : **CRISP-DM** Wirth and Hipp [2000] pour la partie science des données, et un **développement agile par sprints** pour le firmware embarqué.

1.6.1 CRISP-DM appliqué à Sonic AI

La méthodologie **CRISP-DM** Wirth and Hipp [2000] (*Cross-Industry Standard Process for Data Mining*) n’a pas été choisie par défaut. Elle a été choisie parce qu’elle est non-linéaire : ses six phases peuvent être revisitées à tout moment selon ce qu’on découvre. Dans notre cas, cela s’est avéré précieux lors de l’exploration du dataset MIMII à $\text{SNR} = -6\text{dB}$, où plusieurs hypothèses initiales sur la distribution des features ont dû être corrigées après les premières analyses statistiques.

TABLE 1 – Phases CRISP-DM appliquées au projet Sonic AI

Phase	Activités réalisées	Livrable
1. Compréhension métier	Analyse besoins ACTIA ES, étude MIMII, définition KPIs	Cahier des charges
2. Compréhension données	Exploration statistique, analyse SNR, corrélations	Rapport d’analyse
3. Préparation données	EGC, filtrage IIR, WPT, normalisation	Pipeline Python validé
4. Modélisation ML	JSD, PSO, 5 classifieurs, SHAP, ONNX export	Modèles <code>.pkl</code> + <code>.onnx</code>
5. Évaluation	F1, AUC-ROC, matrice confusion, analyse SNR/ID	Rapport de performance
6. Déploiement	STM32Cube.AI, firmware C, tests <i>on-target</i>	Firmware validé

1.6.2 Sprints agiles pour l'embarqué

La partie déploiement a été découpée en cinq sprints de deux semaines chacun, avec un objectif fonctionnel précis à l'issue de chaque sprint. Cette cadence nous a obligés à tester régulièrement sur la vraie carte, ce qui a permis de détecter tôt plusieurs problèmes d'intégration — notamment un stall USB récurrent lié à un `memcpy` CCM → SDRAM trop lent exécuté dans l'ISR, que nous avons résolu en restructurant complètement l'architecture d'acquisition.

- **Sprint 1** : configuration bas niveau STM32F429 — clocks 168 MHz, FMC/SDRAM IS42S16400J, USB OTG HS
- **Sprint 2** : pipeline DSP — filtrage IIR biquad CMSIS-DSP, WPT niveau 4 en *streaming*, extraction features
- **Sprint 3** : intégration XGBoost via STM32Cube.AI, validation latence (3,37 ms mesurée *on-target*)
- **Sprint 4** : moteur de décision hybride et interface LCD tactile ILI9341
- **Sprint 5** : tests *end-to-end*, scénario 20 fenêtres, documentation finale




FIGURE 6 – Méthodologie hybride CRISP-DM / agile embarqué

1.6.3 Planification du Projet

Les livrables du projet ont été définis dès le départ pour répondre à la fois aux attentes académiques de la soutenance et aux besoins concrets d'ACTIA ES :

- **Code source** : firmware STM32 bare-metal complet et pipeline Python de feature engineering, bien structurés, commentés et reproductibles
- **Modèles exportés** : fichiers `.pkl`, `.onnx` et `combined_4machines.onnx` prêts à être intégrés
- **Rapport PFE** : documentation couvrant l'architecture, les décisions techniques et les résultats mesurés
- **Interface de supervision** : dashboard Flask avec explicabilité SHAP et export PDF des rapports de diagnostic

TABLE 2 – Planification temporelle du projet Sonic AI

Étape	Tâches principales	Durée	Livrable
Bibliographie et analyse	Revue littérature, MIMII, architecture système	3 semaines	Cahier des charges
Pipeline ML Python	EGC, WPT, JSD, 5 modèles, SHAP	7 semaines	Modèles <code>.onnx</code>
Déploiement STM32	Cube.AI, firmware C, moteur décision	5 semaines	Firmware STM32
Validation et tests	<i>End-to-end</i> , mesures, documentation	2 semaines	Rapport + soutenance

1.7 Maintenance Industrielle et Industrie 4.0

1.7.1 Évolution des Paradigmes de Maintenance

La maintenance industrielle a une histoire, et cette histoire éclaire pourquoi nous faisons ce que nous faisons. La norme EN 13306 :2017 la définit sobrement comme « l'ensemble des actions techniques et organisationnelles destinées à maintenir ou rétablir un bien dans un état spécifié afin qu'il puisse accomplir une fonction requise ». Mais derrière cette définition neutre se cache une évolution de mentalité fascinante qui s'est étalée sur soixante-dix ans Mobley [2002].

Pendant des décennies, la **maintenance corrective** a régné sans partage. Son principe est brutal dans sa simplicité : on attend que ça casse, puis on répare. Pas besoin

de capteurs, pas besoin d'algorithmes. Juste des pièces de rechange et des techniciens disponibles. Le problème, bien sûr, c'est le coût de l'imprévu. Selon le cabinet Aberdeen Group Aberdeen Group [2014], une heure d'arrêt non planifié coûte en moyenne 260 000 USD dans l'industrie manufacturière lourde. Multiplié par la fréquence des pannes, le chiffre devient insupportable.

La **maintenance préventive** est apparue comme la réponse rationnelle à ce problème : si on intervient régulièrement, avant la panne, on évite les surprises. Les intervalles d'intervention sont calculés statistiquement à partir du temps moyen entre pannes (MTBF), ce qui donne une planification propre et prévisible. Sauf que cette approche a un défaut fondamental qu'on ne peut pas ignorer : elle est aveugle à l'état réel de la machine. On change une pièce encore en bon état parce que le calendrier le dit. R. K. Mobley Mobley [2002] estime que 30 à 40 % des interventions préventives sont inutiles ou prématurées, ce qui représente un gaspillage considérable.

C'est là que la **maintenance prédictive** change les règles du jeu. En combinant des capteurs qui mesurent en continu l'état des machines avec des algorithmes capables d'interpréter ces mesures, on peut détecter les signes de dégradation bien avant la défaillance et intervenir exactement quand c'est nécessaire — ni trop tôt, ni trop tard. McKinsey McKinsey & Company [2023] quantifie les bénéfices : réduction des coûts de maintenance de 10 à 40 %, hausse de disponibilité de 10 à 20 %, et baisse des arrêts non planifiés de 30 à 50 %.




FIGURE 7 – Évolution historique des paradigmes de maintenance industrielle et positionnement de Sonic AI Mobley [2002], McKinsey & Company [2023]

1.7.2 IIoT, Edge AI et TinyML comme Enablers

La maintenance prédictive n'est pas une idée nouvelle. Ce qui est nouveau, c'est qu'on peut maintenant la déployer à grande échelle grâce à la convergence de trois

technologies qui se renforcent mutuellement. L'**IIoT** fournit les données : des capteurs peu coûteux, connectés et déployés partout, qui transforment chaque machine en source continue d'information. L'**Edge Computing** rapproche le traitement de la source : plutôt que d'envoyer tout vers le cloud et d'attendre une réponse, on traite localement, ce qui réduit la latence à quelques millisecondes et supprime la dépendance au réseau. Le **TinyML** Warden and Situnayake [2019] est la pièce qui rend le tout autonome : il permet à un microcontrôleur aussi modeste qu'un STM32F429 de prendre des décisions intelligentes, sans serveur, sans infrastructure, avec une consommation énergétique négligeable.

1.7.3 Surveillance Acoustique — Avantages et Défis

Parmi tous les signaux physiques qu'on peut mesurer sur une machine — vibrations, température, courant, pression — le son occupe une place particulière pour un déploiement industriel à grande échelle. Sa non-intrusivité, d'abord : on n'a pas besoin de modifier la machine ni de l'arrêter pour installer un microphone MEMS à proximité. Sa richesse informationnelle, ensuite : un seul signal acoustique porte simultanément des informations sur la friction, les vibrations, la cavitation, les déséquilibres et les résonances — autant de phénomènes qui nécessiteraient plusieurs capteurs différents pour être captés individuellement de Moura et al. [2011]. Son coût, enfin : un bon microphone MEMS industriel coûte moins d'un dollar, ce qui rend le déploiement à grande échelle réaliste.

Mais la surveillance acoustique a aussi ses difficultés propres, et il serait malhonnête de les minimiser. Le problème principal — et c'est celui qui a structuré l'ensemble de ce projet — est le bruit. Dans une vraie usine, le niveau sonore ambiant peut dépasser 80 à 100 dB(A) selon les environnements. Cela veut dire que le signal utile de la machine peut être noyé dans un bruit ambiant bien plus intense. Le dataset MIMII Purohit et al. [2019] capture précisément cette réalité avec ses scénarios à $\text{SNR} = -6$ dB : le bruit ambiant est deux fois plus énergétique que le signal de la machine. C'est dans ces conditions extrêmes que notre pipeline devait fonctionner.

TABLE 3 – Comparaison des modalités de surveillance pour le CBM

Modalité	Avantages	Limitations
Acoustique (ACM)	Non-intrusif, riche, MEMS < 1 USD, adaptable	Sensible au bruit ambiant, nécessite DSP avancé
Vibration	Haute sensibilité roulements, standard industriel	Contact physique requis, coût élevé
Température	Simple, peu coûteux	Réponse lente, insensible aux défauts précoces
Courant (MCSA)	Applicable à distance	Limité aux machines à induction

1.8 Détection d'Anomalie Acoustique — État de l'Art

1.8.1 Formalisation du Problème

Avant de passer en revue ce que la littérature propose, il est utile de s'accorder sur ce qu'on cherche à faire mathématiquement. Soit $\mathbf{x} \in \mathbb{R}^d$ le vecteur de features acoustiques extrait d'un signal $y(t)$ acquis sur une machine $\mathcal{M}$. Détecter une anomalie revient à apprendre une fonction :

$$f : \mathbb{R}^d \rightarrow \{0, 1\}, \quad f(\mathbf{x}) = \begin{cases} 0 & \text{(Normal)} \\ 1 & \text{(Anomalie)} \end{cases} \quad (1)$$

En pratique, les bons classifieurs ne donnent pas une réponse binaire directe mais une probabilité $p(\text{anomalie} \mid \mathbf{x}) \in [0, 1]$, qu'on compare à un seuil θ . Dans Sonic AI, ce seuil est fixé à $\theta = 0.2$ — délibérément bas. Pourquoi ? Parce qu'en maintenance industrielle, manquer une vraie anomalie (faux négatif) coûte bien plus cher qu'une fausse alarme (faux positif). On préfère envoyer un technicien pour rien plutôt que de laisser une pompe se dégrader silencieusement.

1.8.2 Approches Non Supervisées

La grande majorité des travaux publiés sur la détection d'anomalies acoustiques industrielles s'appuient sur des approches non supervisées. C'est compréhensible :

dans un contexte industriel réel, les données de défaillance étiquetées sont rares, coûteuses à produire, et souvent confidentielles. L'approche de référence est celle proposée par Purohit *et al.* lors de la publication du dataset MIMII Purohit et al. [2019] : un log-mel spectrogram (64 bandes Mel, fenêtre Hann de 1024 échantillons) suivi d'un autoencodeur densément connecté à cinq couches. L'idée est simple — le modèle apprend à reconstruire le son normal, et quand l'erreur de reconstruction dépasse un seuil, il y a anomalie. En conditions standards, l'AUC atteint 65 à 78 % selon la machine. À $\text{SNR} = -6$ dB, elle chute à 60–70 %. C'est insuffisant.

Plusieurs équipes ont cherché à améliorer ces résultats. Giri *et al.* Giri et al. [2020] ont ajouté un mécanisme d'attention dans l'encodeur, portant l'AUC à 79–88 %. Kawaguchi *et al.* Kawaguchi et al. [2021] ont remplacé l'autoencodeur par un MobileNetV2 adapté, atteignant 83–90 % — mais avec une empreinte Flash supérieure à 2 MB, ce qui exclut d'emblée tout déploiement sur Cortex-M4. Plus récemment, Primus et Widmer Primus and Widmer [2022] ont exploré des architectures transformer *self-supervised* sur MIMII-DG et obtenu 84–92 % d'AUC. De très bonnes performances, mais avec des architectures plusieurs ordres de grandeur trop lourdes pour l'embarqué.

1.8.3 Approches Supervisées

Les approches supervisées, qui utilisent des données étiquetées pour entraîner un classifieur discriminant, montrent des performances nettement supérieures dès qu'on dispose des données nécessaires. Zhang *et al.* Zhang et al. [2023] ont proposé WPT + SVM pour les défauts de roulements sur le dataset CWRU, avec des F1-scores de 91–96 % en utilisant la famille db4 au niveau 3. C'est prometteur, mais la complexité SVM à noyau RBF — en $\mathcal{O}(n_{\text{sv}} \cdot d)$ avec parfois plusieurs centaines de vecteurs de support — rend l'inférence difficile à tenir dans le budget mémoire d'un MCU. Ribeiro *et al.* Ribeiro et al. [2024] ont poussé l'expérience plus loin en déployant un CNN léger sur STM32H7 (Cortex-M7, 480 MHz), avec une latence de 15–30 ms et un F1 de 88–93 %. Un résultat intéressant, mais obtenu sur un processeur deux fois plus puissant que notre cible et sans aucun mécanisme d'explicabilité.

1.8.4 Analyse des Lacunes et Contributions de Sonic AI

En lisant cette littérature, on est frappé par quatre lacunes qui reviennent systématiquement et que personne, à notre connaissance, n'a adressées toutes à la fois :

- **L1 — Incompatibilité embarquée** : les méthodes les plus performantes (CNN profonds, Transformer, VAE) requièrent plus d'1 MB de Flash et plus de 100 KB de RAM, ce qui les rend incompatibles avec un Cortex-M4 standard comme le STM32F429

- **L2 — Fragilité à bas SNR** : les approches non supervisées décrochent à 60–70 % d'AUC à $\text{SNR} = -6$ dB, un niveau qui n'est pas acceptable pour une application industrielle réelle
- **L3 — Boîte noire sans explicabilité** : aucun des travaux publiés n'intègre un mécanisme type SHAP ou LIME, ce qui rend les diagnostics opaques et difficiles à accepter pour un opérateur de maintenance
- **L4 — Absence de validation *on-target*** : la grande majorité des travaux reportent des performances en simulation ou sur serveur, sans jamais mesurer la latence réelle sur un MCU Cortex-M4

Sonic AI adresse ces quatre lacunes simultanément. Les résultats *on-target* (F1 de 0.86 à 0.98, latence de 3.37 à 5.34 ms, 396 KB de Flash, 468 B de RAM) montrent que le compromis performance/frugalité est atteignable, même dans les conditions acoustiques les plus difficiles.

TABLE 4 – Comparaison avec les travaux de l'état de l'art

Travail	Méthode	Dataset	F1 / AUC	Embarqué
Purohit <i>et al.</i> Purohit et al. [2019]	Log-Mel + Autoencoder	MIMII	AUC 0.65–0.78	Non
Giri <i>et al.</i> Giri et al. [2020]	CNN + Attention	MIMII	AUC 0.79–0.88	Non
Kawaguchi <i>et al.</i> Kawaguchi et al. [2021]	MobileNetV2 + AE	MIMII	AUC 0.83–0.90	Non (>2 MB)
Primus & Widmer Primus and Widmer [2022]	Self-supervised Transf.	MIMII-DG	AUC 0.84–0.92	Non
Zhang <i>et al.</i> Zhang et al. [2023]	WPT + SVM	CWRU	F1 0.91–0.96	Partiel
Ribeiro <i>et al.</i> Ribeiro et al. [2024]	CNN + MFCC	Bearing	F1 0.88–0.93	Cortex-M7
Sonic AI (ce travail)	WPT-L4 + JSD + XGBoost + SHAP	MIMII (−6 dB)	F1 0.86–0.98	STM32F429, 3.37 ms

1.9 Traitement du Signal Acoustique — Fondements Théoriques

1.9.1 Représentations Temps-Fréquence

Un signal acoustique de machine industrielle est ce qu'on appelle un signal non-stationnaire : ses propriétés spectrales changent au cours du temps, que ce soit lors d'un démarrage, d'une montée en charge ou d'une dégradation progressive. Analyser un tel signal uniquement dans le domaine temporel ne révèle pas grand chose. L'analyser uniquement dans le domaine fréquentiel (par FFT globale) perd l'information temporelle. Il faut donc une représentation qui combine les deux, et plusieurs approches existent.

1.9.1.1 Transformée de Fourier à Court Terme (STFT)

La STFT est l'approche la plus connue ?. Elle découpe le signal en fenêtres temporelles glissantes de durée fixe T_w et calcule le spectre de Fourier sur chacune :

$$\text{STFT}\{x\}(\tau, f) = \int_{-\infty}^{+\infty} x(t) w(t - \tau) e^{-j2\pi ft} dt \quad (2)$$

où $w(t)$ est la fenêtre d'analyse (Hamming ou Hann). Son talon d'Achille est le compromis temps-fréquence imposé par le principe d'incertitude de Heisenberg-Gabor, $\Delta t \cdot \Delta f \geq 1/(4\pi)$: une fenêtre courte donne une bonne résolution temporelle mais une mauvaise résolution fréquentielle, et vice versa. Ce compromis fixe et non-adaptatif la rend inadaptée à nos signaux, qui peuvent présenter en même temps des impulsions très rapides (chocs de roulements) et des harmoniques très basses (régime de rotation).

1.9.1.2 Transformée en Ondelettes Discrète (DWT)

La DWT, formalisée par Mallat ?, résout le problème de résolution fixe en utilisant des bases d'analyse à résolution variable : haute résolution temporelle pour les hautes fréquences, haute résolution fréquentielle pour les basses fréquences. C'est exactement ce dont on a besoin pour les signaux de machines. Mais la DWT classique a un angle mort : elle ne décompose récursivement que la sous-bande basse fréquence (approximation), laissant les sous-bandes hautes fréquences (détail) à leur résolution initiale. Si un défaut se manifeste dans une de ces sous-bandes de détail, on risque de le manquer.

1.9.2 Wavelet Packet Transform (WPT)


C'est précisément ce problème que la **WPT** règle. En décomposant récursivement *toutes* les sous-bandes — pas seulement les approximations — à chaque niveau, elle produit une partition uniforme et complète de l'axe fréquentiel. Avec $f_s = 16\,000$ Hz et un niveau de décomposition $L = 4$, on obtient $2^4 = 16$ nœuds feuilles qui couvrent chacun une bande de $\Delta f = f_s/2^{L+1} = 500$ Hz. Cette granularité de 500 Hz n'est pas un hasard : elle permet de résoudre les fréquences de cavitation (200–800 Hz), les défauts de roulements (300–3 000 Hz), l'imbalance (50–200 Hz) et les turbulences aérodynamiques (1–7 kHz) des quatre machines MIMII.

Mathématiquement, la décomposition s'effectue récursivement via deux filtres miroirs en quadrature (QMF) ? :

$$W_{j+1}^{(2n)}[k] = \sum_{\ell} h[\ell - 2k] W_j^{(n)}[\ell] \quad (\text{sous-bande passe-bas}) \quad (3)$$

$$W_{j+1}^{(2n+1)}[k] = \sum_{\ell} g[\ell - 2k] W_j^{(n)}[\ell] \quad (\text{sous-bande passe-haut}) \quad (4)$$

où $W_j^{(n)}[k]$ est le signal au nœud n au niveau j , et k est l'indice temporel après la décimation par 2.



figures/wpt_tree.png

FIGURE 8 – Arbre de décomposition WPT de niveau 4 (Coiflet-5, $f_s = 16$ kHz) — 16 nœuds feuilles $\times$ 3 descripteurs = 48 features ?

1.9.3 Famille d'Ondelettes Coiflet-5

Le choix de la famille d'ondelettes n'est pas anodin : il conditionne la qualité de la décomposition et, par conséquent, la pertinence des features extraites. Nous avons retenu la famille Coiflet d'ordre 5 (`coif5`) après avoir comparé plusieurs alternatives sur nos données. Ce qui rend les Coiflets spéciaux ?, c'est leur double propriété de moments nuls : 5 moments nuls à la fois pour la fonction d'ondelette ψ et pour la fonction d'échelle φ . En pratique, cela signifie une précision accrue pour les fonctions régulières — exactement ce que produisent les machines en fonctionnement nominal. La quasi-symétrie du filtre (30 coefficients, très proche d'un filtre symétrique) réduit les distorsions de phase dans les coefficients, ce qui est crucial pour que des indicateurs comme le kurtosis et l'entropie conservent leur sens physique d'un nœud

à l'autre.

1.9.4 Descripteurs Statistiques par Nœud WPT

Une fois les 16 nœuds feuilles calculés, il faut en extraire des nombres exploitables par un classifieur. Nous avons choisi trois descripteurs statistiques pour chaque nœud, non par habitude mais parce que chacun capture quelque chose de différent sur ce qu'une anomalie fait au signal.

1.9.4.1 Valeur Efficace (RMS)

La RMS mesure l'énergie dans la sous-bande. Quand une machine développe une résonance ou un phénomène de cavitation, l'énergie se concentre dans certaines bandes fréquentielles, et la RMS de ces nœuds augmente de manière détectable :

$$\text{RMS}_i = \sqrt{\frac{1}{N_c} \sum_{k=0}^{N_c-1} [W_4^{(i)}[k]]^2} \quad (5)$$

1.9.4.2 Kurtosis

Le kurtosis mesure l'impulsivité : est-ce que le signal dans cette sous-bande est lisse et continu, ou est-ce qu'il contient des pics brefs et intenses ? Dyer et Stewart ? ont montré dès 1978 que le kurtosis est l'un des premiers indicateurs à réagir lors d'un défaut de roulement naissant, bien avant que la RMS ne bouge. C'est une propriété précieuse pour la détection précoce.

$$\text{Kurt}_i = \frac{\frac{1}{N_c} \sum_{k=0}^{N_c-1} (W_4^{(i)}[k] - \mu_i)^4}{\sigma_i^4} - 3 \quad (6)$$

où μ_i et σ_i sont la moyenne et l'écart-type des coefficients. Un kurtosis positif signale des impulsions mécaniques caractéristiques.

1.9.4.3 Entropie de Shannon

L'entropie mesure le désordre. Un signal harmonique régulier a une faible entropie (l'énergie est concentrée sur quelques coefficients). Un signal bruité a une entropie élevée (l'énergie est dispersée uniformément). Les anomalies mécaniques tendent à perturber cette structure de façon caractéristique — certains défauts augmentent l'entropie dans les hautes fréquences, d'autres la diminuent dans les basses fréquences.

$$H_i = - \sum_{k=0}^{N_c-1} p_k \log_2 p_k, \quad p_k = \frac{\left[W_4^{(i)}[k] \right]^2}{\sum_{j=0}^{N_c-1} \left[W_4^{(i)}[j] \right]^2} \quad (7)$$

Ces trois descripteurs appliqués aux 16 nœuds donnent $3 \times 16 = 48$ features WPT. En ajoutant 13 features temporelles (RMS global, kurtosis, skewness, facteur de crête, etc.) et 5 features fréquentielles (centroïde spectral, largeur de bande, etc.), on arrive à $d = 66$ features brutes au total.

1.9.5 Sélection de Features par Divergence Jensen-Shannon

Soixante-six features, c'est beaucoup. Certaines discriminent bien, d'autres pas. Certaines apportent une information nouvelle, d'autres répètent ce que leurs voisines disent déjà. La divergence Jensen-Shannon (JSD) nous permet de garder uniquement celles qui comptent vraiment, pour chaque type de machine séparément.

La JSD mesure à quel point deux distributions de probabilité sont différentes. Pour une feature j , on estime la distribution des valeurs en classe normale (P_j) et en classe anormale (Q_j) via des histogrammes à 50 bins, après standardisation. Si les deux distributions se ressemblent beaucoup, la feature ne discrimine pas — on la retire. Si elles sont bien séparées, la feature est discriminante — on la garde :

$$\text{JSD}(P_j \| Q_j) = \frac{1}{2} D_{\text{KL}}(P_j \| M_j) + \frac{1}{2} D_{\text{KL}}(Q_j \| M_j), \quad M_j = \frac{P_j + Q_j}{2} \quad (8)$$

$$D_{\text{KL}}(P \| M) = \sum_x P(x) \log_2 \frac{P(x)}{M(x)} \quad (9)$$

Une feature est retenue si son score JSD dépasse un seuil τ_m ajusté per-machine. Un filtre de corrélation de Pearson ($r \geq 0.95$) élimine ensuite les redondances. Au final : Pump (40 features), Fan (33), Slider (39), Valve (55).

1.9.6 Filtrage IIR Butterworth

Avant d'entrer dans la WPT, le signal acoustique passe par un filtre passe-bande. Nous avons choisi un filtre Butterworth d'ordre 4 sur la bande [300–7 000 Hz]. La famille Butterworth a une propriété qui nous convient parfaitement : elle est « maximale plate » dans la bande passante ?, ce qui signifie qu'elle ne déforme pas les amplitudes relatives des composantes que nous cherchons à analyser. Les 300 Hz inférieurs éliminent les vibrations d'infrastructure sans intérêt diagnostique ; les 7 000 Hz supérieurs couvrent toutes les bandes caractéristiques des quatre machines, avec une

marge confortable de 1000 Hz par rapport à la fréquence de Nyquist. Sur la carte STM32F429, ce filtre est implémenté via la structure biquad DF2T de CMSIS-DSP (`arm_biquad_cascade_df2_f32`, 4 étages) ?.

$$H(s) = \frac{\omega_0^{2n}}{\prod_{k=1}^n \left(s^2 + \frac{\omega_0}{Q_k} s + \omega_0^2 \right)} \quad (10)$$




FIGURE 9 – Réponse fréquentielle du filtre Butterworth passe-bande d'ordre 4 : amplitude (gauche) et phase nulle (droite) ?

1.10 Conclusion

Ce chapitre nous a permis de poser les fondations de tout ce qui suit. Nous avons présenté l'entreprise qui nous a accueillis, expliqué pourquoi ce projet répond à un besoin industriel réel, et posé les objectifs qui ont guidé chaque décision technique. Nous avons montré que la maintenance prédictive acoustique est un problème difficile — notamment à cause du bruit ambiant à $\text{SNR} = -6$ dB — et que les solutions existantes ne répondent pas simultanément à toutes les contraintes que nous nous sommes fixées.

L'état de l'art nous a été utile de deux façons. Positivement, il nous a indiqué quelles représentations et quels modèles méritent d'être explorés pour ce type de problème. Négativement, il nous a révélé quatre lacunes — incompatibilité embarquée, fragilité à bas SNR, absence d'explicabilité, manque de validation *on-target* — qui définissent exactement ce que Sonic AI cherche à apporter.

Les outils théoriques présentés en fin de chapitre — STFT, DWT, WPT, Coiflet-5, RMS, kurtosis, entropie de Shannon, JSD, filtre Butterworth — ne sont pas de la théorie pour la théorie. Chacun de ces éléments joue un rôle précis dans le pipeline que nous décrirons au Chapitre 2, et les avoir formalisés ici permet d'y arriver avec les bons concepts déjà en main.

Le Chapitre 2 démarre par la description détaillée du dataset MIMII, puis détaille l'intégralité du pipeline ML : prétraitement, extraction de features, sélection JSD, entraînement et benchmarking des cinq classifieurs PSO-optimisés, et intégration de l'explicabilité TreeSHAP dans l'interface Flask.

Bibliographie

- Aberdeen Group. The state of predictive maintenance, 2014.
- ACTIA Engineering Services. Actia engineering services sa official website, 2024. URL <https://www.actia-es.com.tn>.
- E. P. de Moura, C. R. Souto, A. A. Silva, and M. A. S. Paula. Evaluation of bearing faults using acoustic emission and vibration signals. *Journal of Acoustic Emission*, 29 :222–231, 2011.
- Ritwik Giri, Sriram Tenneti, Karim Helwani, Umut Sen, and Arvinth Krishnaswamy. Self-supervised classification for anomalous sound detection. pages 61–65, 2020.
- Yohei Kawaguchi, Keisuke Imoto, Yuma Koizumi, Noboru Harada, Daisuke Niizumi, Vassilios Vassiliades, Gerasimos Spanakis, Toni Heittola, and Tuomas Virtanen. Description and discussion on dcase 2021 challenge task 2 : Unsupervised anomalous sound detection for machine condition monitoring under domain shift conditions. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events 2021 Workshop (DCASE2021)*, 2021.
- Heiner Lasi, Peter Fettke, Hans-Georg Kemper, Thomas Feld, and Michael Hoffmann. Industry 4.0. *Business & Information Systems Engineering*, 6(4) :239–242, 2014.
- Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, pages 4765–4774, 2017.
- McKinsey & Company. The economic potential of generative ai : The next productivity frontier, 2023.
- R. Keith Mobley. *An Introduction to Predictive Maintenance*. Butterworth-Heinemann, 2nd edition, 2002.
- Paul Primus and Gerhard Widmer. Anomalous sound detection with self-supervised representation learning. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events 2022 Workshop (DCASE2022)*, 2022.
- Harsh Purohit, Ryo Tanabe, Kenji Ichige, Takashi Endo, Yuki Nikaido, Keisuke Suefusa, and Yohei Kawaguchi. Mimii dataset : Sound dataset for malfunctioning industrial machine investigation and inspection. *arXiv preprint arXiv :1909.02847*, 2019.

- L. Ribeiro, J. Barbosa, and P. Leita. Edge-based convolutional neural network for bearing anomaly detection on resource-constrained microcontrollers. *IEEE Transactions on Industrial Informatics*, 2024.
- Pete Warden and Daniel Situnayake. *TinyML : Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers*. O'Reilly Media, 2019.
- Ruediger Wirth and Jochen Hipp. Crisp-dm : Towards a standard process model for data mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, pages 29–39, 2000.
- Dong Zhang, Zhi-Hua Zhang, and Yong-Ping Zhang. Bearing fault diagnosis based on wavelet packet transform and support vector machine. *Journal of Physics : Conference Series*, 2462 :012015, 2023.